数据分析项目报告

Olist 巴西电商

履约与增长分析

从 155 万行交易数据，看「超时 → 差评 → 不复购」
如何拖住增长

数据	Brazilian E-Commerce Public Dataset by Olist
规模	9 张表 / 155 万行 / 2016.09 – 2018.10
工具	MySQL 8.0 · Python 3.14 · pandas · matplotlib

2026 年 10 月

摘要

> Olist 的增长瓶颈不在获客，在履约。大促把订单量推到月均的 1.5 倍，物流跟不上，用户给差评、不再回来；而平台本身的复购率只有 4–5%，补不上缺口——所以增长只能靠一波一波地拉新，形不成复利。

三个核心数字

6.7% → 32.5%

超时订单只占样本的 6.7%，却贡献了 32.5% 的差评。
超时订单的差评率约 62%，准时订单只有 9.2%——差 6.7 倍。

4.29 → 2.11

准时订单平均 4.29 分；超时 1–3 天掉到 3.29；超 4–7 天崩到 2.11。
超 8 天后见底（1.68），再晚也不会更差。

2.52% vs 3.82%

首单「超时 + 差评」的客户复购率 2.52%，准时好评组 3.82%。
差异显著（$\chi^2=14.53$, $p<0.001$），但幅度只有 1.3 个百分点。

三条建议

优先级	建议	效果	成本
1	大促期间 ETA 放宽 15%（22.7 → 26 天）	减 1,100 单超时 / 590 个差评	零
2	按州设 SLA，取消全国统一承诺	减 2,190 单超时 / 1,160 个差评	低
3	超时预警前置到「超时前 1 天」	减 320 个差评	中

报告结构

1 背景与选题 · 2 数据与口径 · 3 生意盘子 · 4 履约质量 · 5 时效与满意度 · 6 复购验证 · 7 结论与建议 · 8 局限 · 附录

1 背景与选题

1.1 数据是什么

Olist 是巴西的一家电商平台（marketplace），本次分析使用其 2016 年 9 月至 2018 年 10 月的脱敏交易数据，共 9 张表、约 155 万行，涵盖订单、商品明细、支付、评价、客户、卖家与地理信息。

1.2 为什么选这个题：先做「能力矩阵」

拿到数据后没有直接想「做什么图」，而是列出常见分析主题，逐条判断这份数据是否支撑：

分析主题	必需字段	是否具备	判定
规模与趋势	金额 + 下单时间	✓	可做，但平庸
转化漏斗	浏览 / 加购 / 购买日志	✗ 只有成单	做不了
留存与复购	用户唯一标识 + 时间	△ 复购率仅 4–5%	做不了主线
履约时效	下单 / 交运 / 送达 / 承诺 四个时间戳	✓✓	强项
满意度归因	评分 + 履约字段	✓✓	强项
毛利 / 广告效率	成本、曝光、点击、花费	✗	做不了

结论：这份数据唯一「字段齐全、且能从头走到尾」的路径是——

> 履约时效 → 满意度 → 复购：有客观过程（时间戳）、有主观结果（评分），两者能通过 order_id 连接。这是大多数公开数据集不具备的条件。

1.3 分析框架

全文按「现象 → 归因 → 后果 → 建议」四段推进，每章只回答一个问题：

章节	要回答的问题	核心方法
第 1 章	生意怎么样	建基准、转相对值、看集中度
第 2 章	凭什么做到（履约）	分布 / 空间 / 时间三维拆分 + 排除法
第 3 章	慢的代价多大	分箱看形状（非线性）+ 主动证伪
第 4 章	用户真的走了吗	先诊断测量偏差，再做对比与检验
第 5 章	该做什么	做减法、按成本效果排序、算钱

2 数据与口径

2.1 九张表的关系

表	行数	一行 = 什么	在分析中的角色
orders	99,441	一个订单	主表，含 4 个时间戳 + 1 个承诺日
order_items	112,650	订单里的一个商品项	GMV 唯一来源（price / freight）
order_payments	103,886	一次支付动作	支付结构，与金额对账

表	行数	一行 = 什么	在分析中的角色
order_reviews	99,224	一条评价	评分（核心因变量）
customers	99,441	一张订单的客户记录	customer_unique_id 用于复购
products	32,951	一个商品	品类维度
sellers	3,095	一个卖家	供给端（本项目未深入）
geolocation	1,000,163	一条邮编-坐标对	未使用（成本高、收益低）
category_translation	71	一个品类的翻译	品类可读化

2.2 数据质量问题与处理（均为实测）

#	问题	规模	影响	处理
1	物流日期为空字符串	2,980 行	严格模式下导入静默丢 3%	先入字符串再转 NULL
2	review_id 重复	789 个 ID / 814 行	单列主键挡掉 814 条	改复合主键 (review_id, order_id)
3	评论含换行符	3,852 条	CSV 解析错行，少 815 条	只导评分等定长字段
4	品类缺失	610 个商品	占比分母差 1.33%	归入「未标注」，图注说明
5	翻译表缺 2 个品类	13 个商品	JOIN 匹配不上	按葡语意译补齐
6	有支付无明细	775 单	INNER JOIN 丢单	报告说明，不影响 GMV
7	customers 与订单同为 99,441 行	—	用 customer_id 算复购率恒为 0	改用 customer_unique_id

2.3 口径定义

指标	定义	备注
样本范围	order_status = 'delivered'	96,478 单，占全部订单 97%
GMV	SUM(price)，不含运费	运费单列为 freight
AOV	总 GMV ÷ 总订单数	137.04（含运费 159.83）
配送天数	DATEDIFF(delivered, purchase)	按整天截断
超时	DATEDIFF(delivered, estimated) > 0	按整天 6.77%；按小时 8.11%
复购	customer_unique_id 名下订单 ≥ 2	全量 3.12%；控制观察期后 5.51%
差评	review_score ≤ 2	占比 12.77%
时间窗	2017-01 – 2018-08	首尾月份不完整，已截断

3 生意盘子：先定义什么叫「正常」

第 1 章的任务不是「介绍数据」，而是为后面三章建立参照系。它回答三个问题：盘子多大、怎么长的、靠什么撑着。

观察	结论
规模	2017-01 至 2018-08 累计 GMV 1,318 万美元、9.6 万单，AOV 137 美元（不含运费）
节奏	月度 GMV 从 11.2 万涨到 83.9 万，20 个月 7.5 倍；2017-11 黑五达 98.8 万（月均 1.5 倍）

观察	结论
地域	SP 一州占 38.4%，前三州合计 63.4%，Top10 覆盖 87.9%
品类	第一名仅 9.33%，Top10 只覆盖 62.5%
支付	信用卡 78.45%；boleto（线下单据）17.97%

> 地域是收敛的（Top10 88%），品类是发散的（Top10 62.5%）——资源按州配，品类只能广撒试探。

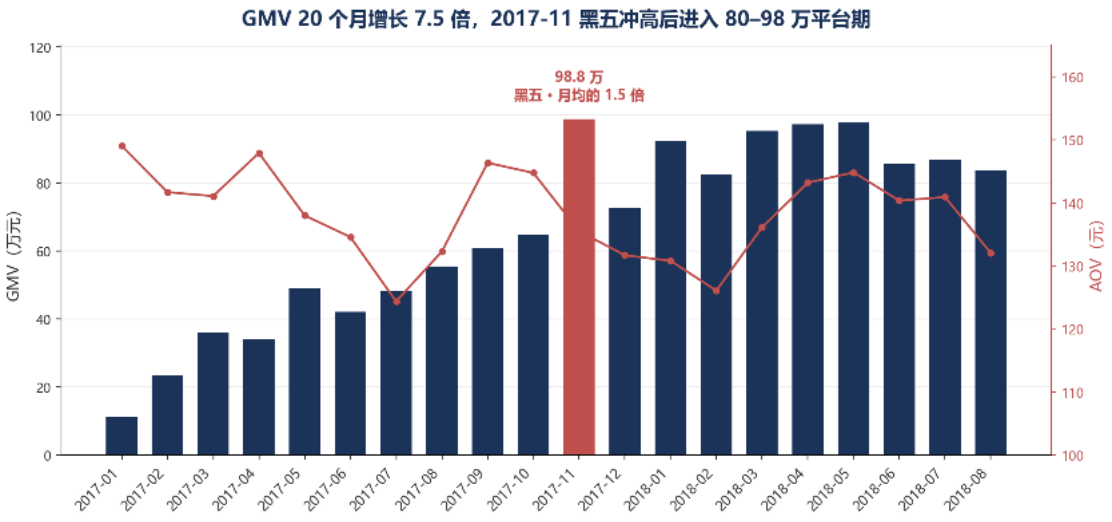


图 1　月度 GMV 与 AOV：黑五冲高后进入 80–98 万平台期

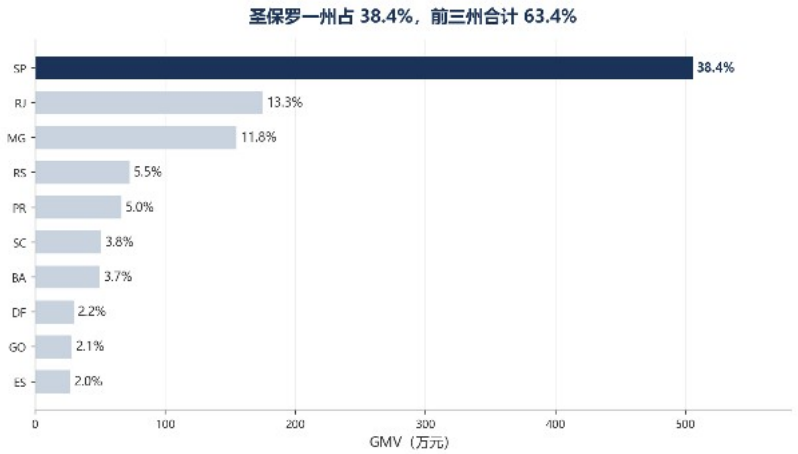


图 2　州 GMV 分布：圣保罗一州占 38.4%

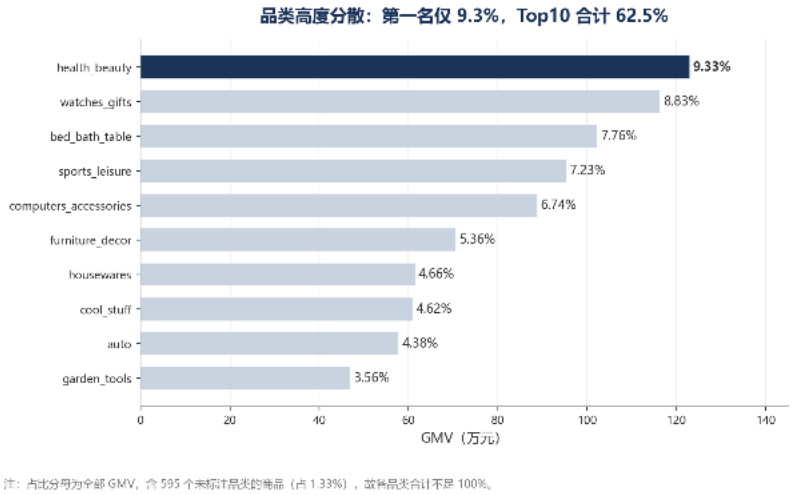


图 3　品类 GMV 分布：第一名仅 9.3%，Top10 合计 62.5%

本章核对数字

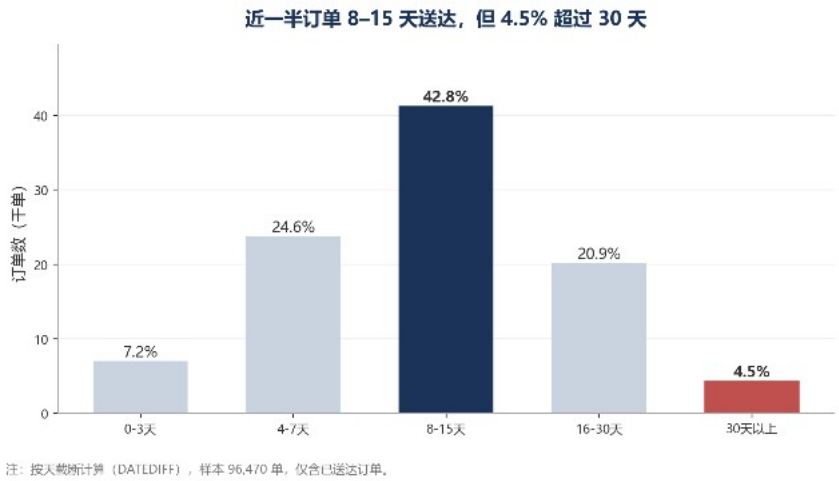
指标	值	指标	值
全部订单	99,441	宽表行数（有明细）	98,666
已送达订单	96,478	GMV（全期）	13,221,498.11
运费合计	2,198,275.64	AOV 不含 / 含运费	137.04 / 159.83
20 个月订单	96,211	20 个月 GMV	13,181,027.13
月均订单	4,811	月均 GMV	659,051.36
2017-11 订单	7,289	2017-11 GMV	987,765.37

4 履约质量：问题在哪、有多大

第 1 章留下的假设是「物流是增长瓶颈」。第 2 章用三个维度定位：慢不慢（分布）、哪里慢（空间）、什么时候慢（时间）。

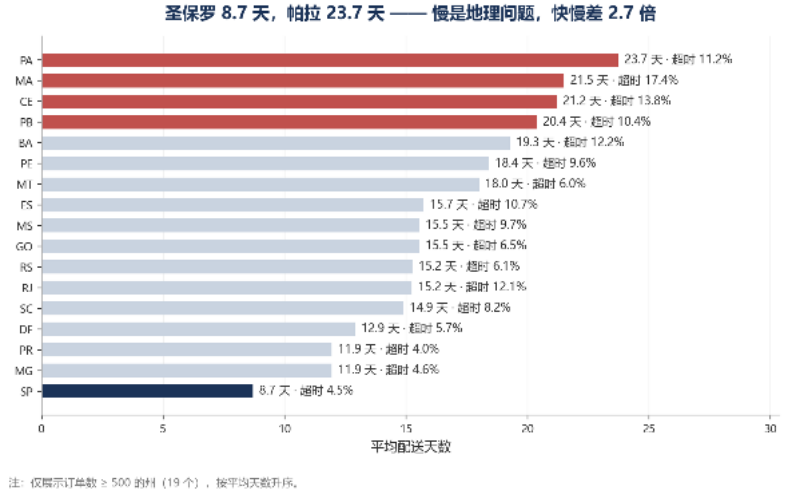
指标	结果
样本	96,470 单（已送达且有送达时间）
配送时长	均值 12.50 天，中位数 10 天，P90 23 天，最长 210 天
分布	42.8% 落在 8–15 天；4.45% 超过 30 天
超时	6,534 单，超时率 6.77%；超时单平均超 10.6 天，准时单平均提前 13.5 天
地域	SP 8.70 天 / 超时率 4.49%；PA 23.73 天——快慢差 2.7 倍
品类	10.87–13.66 天，超时率 5.00%–7.56%——几乎没有区分度
大促	2018-03 平均 16.24 天、超时率 18.96%，是常态的 5 倍

> 品类之间几乎没有差异（10.9–13.7 天），而州之间差 2.7 倍——这一条排除了「某些商品难配送」的解释，把问题锁定在地理上。



注：按天截断计算（DATEDIFF），样本 96,470 单，仅含已送达订单。

图 4　配送时长分布：近一半订单 8–15 天送达



注：仅展示订单数 ≥ 500 的州（19 个），按平均天数升序。

图 5　分州配送表现：快慢差 2.7 倍

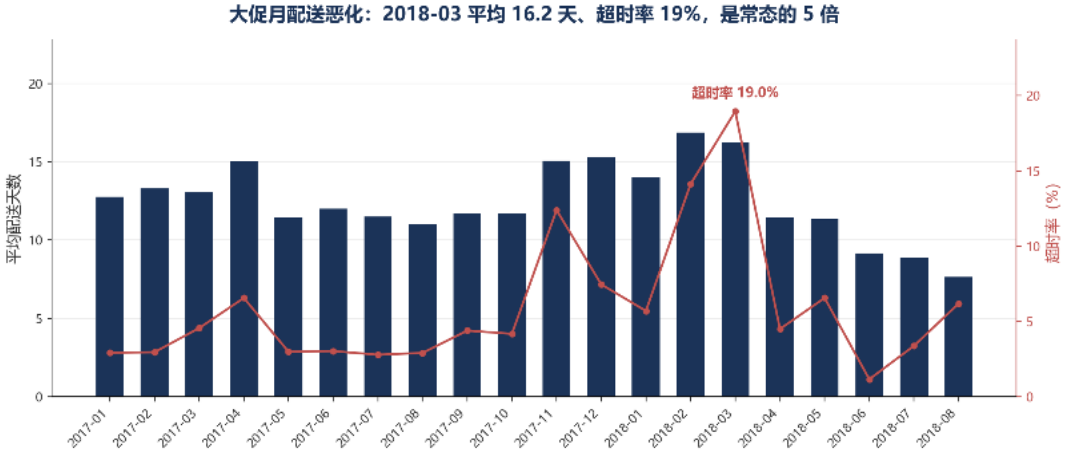


图 6　月度配送与超时率：大促月超时率是常态的 5 倍

关键发现：承诺收紧的悖论

如果只看实际天数，结论是「物流在改善」（12.75 → 7.66 天）。加上承诺天数（ETA）之后，才看到另一件事：

月份	实际天数	承诺天数	缓冲	超时率
2017-01	12.75	40.2	27.5 天	2.93%

月份	实际天数	承诺天数	缓冲	超时率
2018-06	9.16	28.4	19.2 天	1.16%
2017-11	15.07	23.2	8.1 天	12.40%
2018-08	**7.66（最快）**	**15.8**	**8.1 天**	**6.19%**

> 承诺从 40 天压到 16 天，实际从 12.8 天降到 7.7 天，缓冲从 27 天缩到 8 天。同样的缓冲下，实际 15 天时超时率 12.4%，实际 7.7 天时只有 6.2%。超时率不是纯粹的物流问题，而是「承诺 × 履约」的函数。



图 7　承诺 vs 实际：送得更快，但因为承诺收得更紧，反而更容易超时

5 时效与满意度：代价是断崖式的

第 2 章证明「慢」，第 3 章量化「慢的代价」。样本为已送达且有评价的 95,824 单（覆盖率 99.3%；525 单有多条评价，按订单取平均）。

按超时程度分箱：断崖在哪

分箱	订单数	平均分	差评率	一星率
准时或提前	89,443	4.291	9.23%	6.58%
超 1–3 天	1,852	3.291	32.18%	25.11%
超 4–7 天	1,748	2.106	67.56%	58.47%
超 8–15 天	1,601	1.675	79.95%	70.14%
超 15 天以上	**1,180**	**1.728**	**78.14%**	**69.15%**

- 伤害是跳变的：从准时到超 1 天，平均分掉 1.0，差评率从 9% 跳到 32%
- 超 8 天见底：1.675 与 1.728 几乎相同，再晚也不会更差
- 补救窗口只在超时后 1–3 天：4 天后评分已崩到 2.11，补偿换不回评价

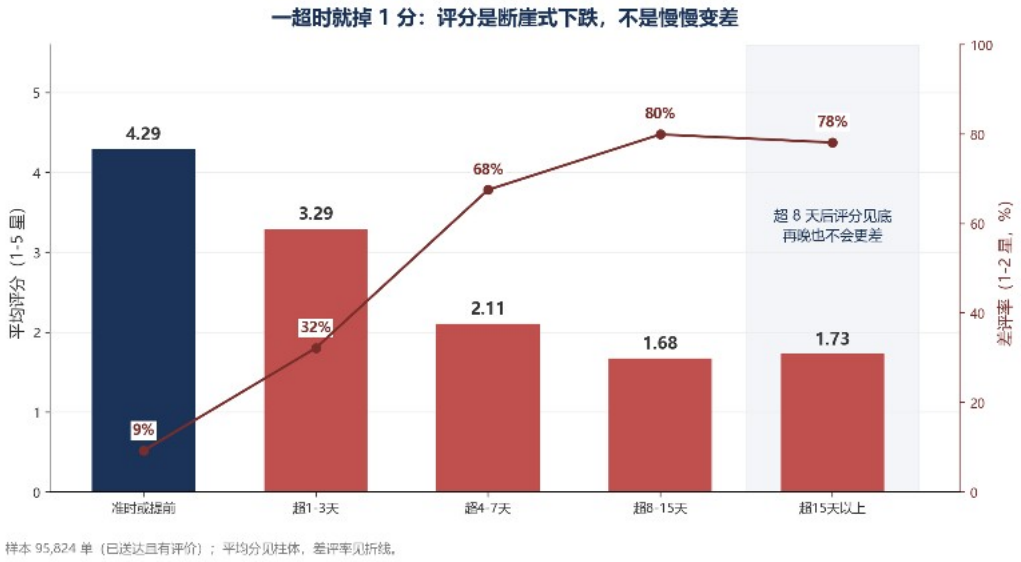


图 8　断崖曲线：评分是台阶式下跌，不是斜坡

归因：超时只占 6.7%，却贡献 32.5% 的差评

类别	订单数	其中超时	超时占比
差评（1–2 星）	12,236	3,979	32.52%
中评（3 星）	7,969	696	8.73%
好评（4–5 星）	75,619	1,706	2.26%

换算：超时订单的差评率约 62%，准时订单只有 9.2%——差 6.7 倍。

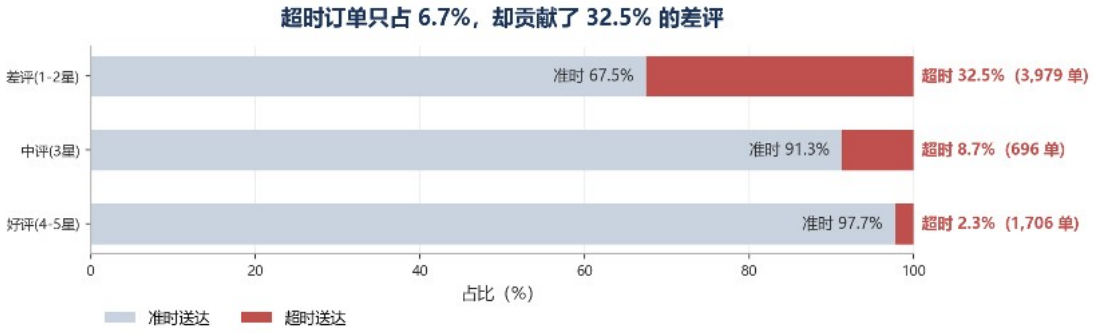


图 9　差评/中评/好评中的超时浓度对比

交叉验证：排除「偏远州用户更挑剔」

州	准时组平均分	超时组平均分	落差
SP	4.33	2.55	−1.78
RJ	4.24	1.91	−2.33
MG	4.28	2.36	−1.92
BA	4.14	2.36	−1.78
PA	4.15	1.92	−2.23

每个州的准时组都在 4.1–4.4，超时组都在 1.9–2.7。无论哪个州，超时都让评分掉 1.7–2.4 分。替代解释被排除——这是本章最重要的一步：光有相关不够，要主动反驳最强的反驳。

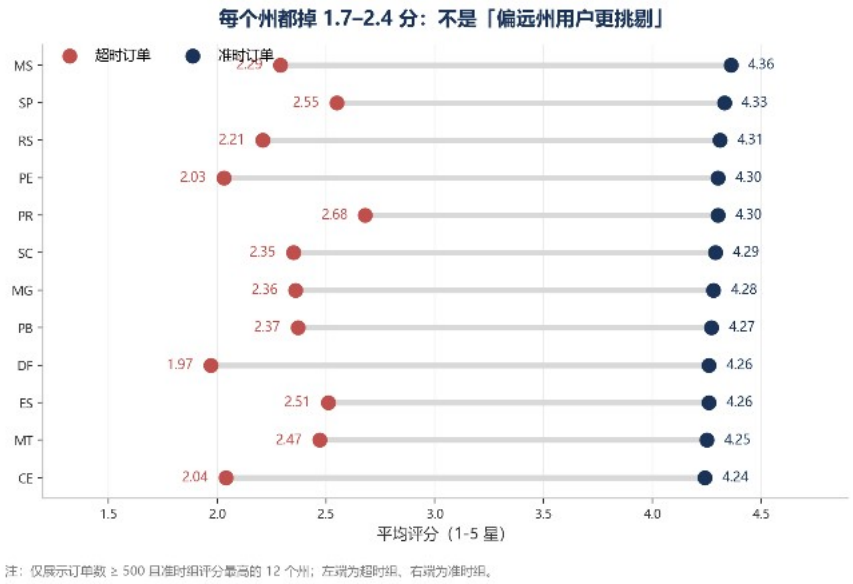


图 10　分州哑铃图：每个州都掉 1.7–2.4 分

6 复购验证：因果链闭合了吗

第 3 章用的是「用户说了什么」（评分），第 4 章用「用户做了什么」（复购）。样本为首购于 2018-04 前的 71,186 名客户（保证至少 6 个月观察期）。

三个测量陷阱（先诊断，再分析）

陷阱	现象	处理
右截断	2018-08 首购的客户只有 2 个月窗口，复购率被低估至 0.81%	只取首购 ≤ 2018-04
拆单	30.93% 的「第二单」发生在首单后 1 天内——不是复购，是同一笔购买被拆单	单独报告，不并入复购率
地板效应	整体复购率仅 4–5%，任何因素都拉不开差距	解读时说明效应受限

首单体验 × 是否复购

分组	客户数	复购率
准时 · 好评	52,052	3.82%
准时 · 中评	5,555	3.65%
准时 · 差评	7,839	3.66%
超时 · 好评	1,225	3.67%
超时 · 中评	538	3.35%
超时 • 差评	**3,371**	**2.52%**

卡方检验（2×2）：准时 vs 超时 $\chi^2=11.09$（p=8.7e-04）；好评 vs 差评 $\chi^2=6.04$（p=0.014）；准时·好评 vs 超时·差评 $\chi^2=14.53$（p=1.4e-04）。三项均显著。

> 方向明确、统计显著，但绝对幅度只有 1.3 个百分点（相对 −34%）。原因是地板效应：平台整体复购率只有 3–5%，体验好坏都很难拉开差距。这条链成立但不强——它解释了「为什么增长没有复利」，但不足以说「改善体验就能翻倍」。

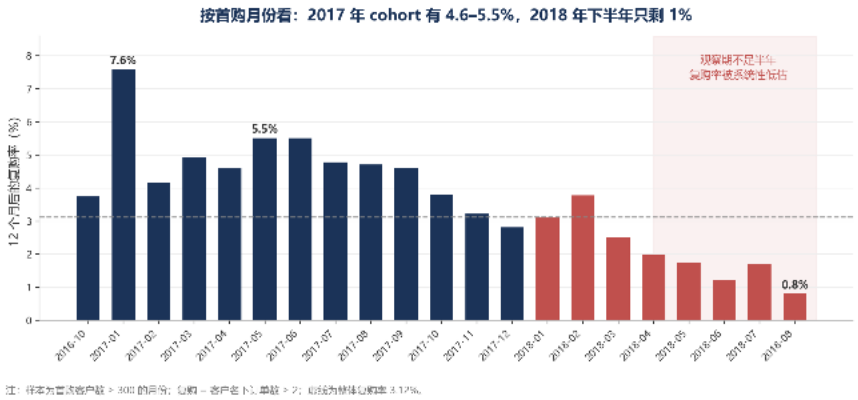


图 11　按首购月份看复购率：2017 年 cohort 有 4.6–5.5%，2018 年下半年只剩 1%

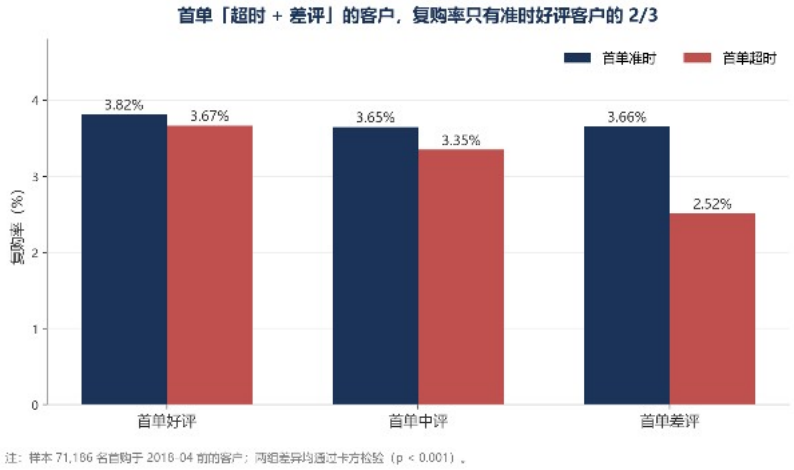


图 12　首单「超时 + 差评」的客户复购率只有准时好评组的 2/3

一个指标，三个口径

口径	数值	什么时候用
数据原样	3.12%	和别人对齐、对外沟通
剔除同日拆单	≈ 2.2%	看真实跨期行为
控制观察期（2017 cohort）	4.6–5.5%	看长期忠诚度

脱离品类谈复购率没有意义：快消月复购 30%+、服饰季度 20–30%、而家具家居礼品年复购 5% 左右是正常的。真正的问题不是「复购低」，而是「这门生意只能靠不断拉新」。

7 结论与建议

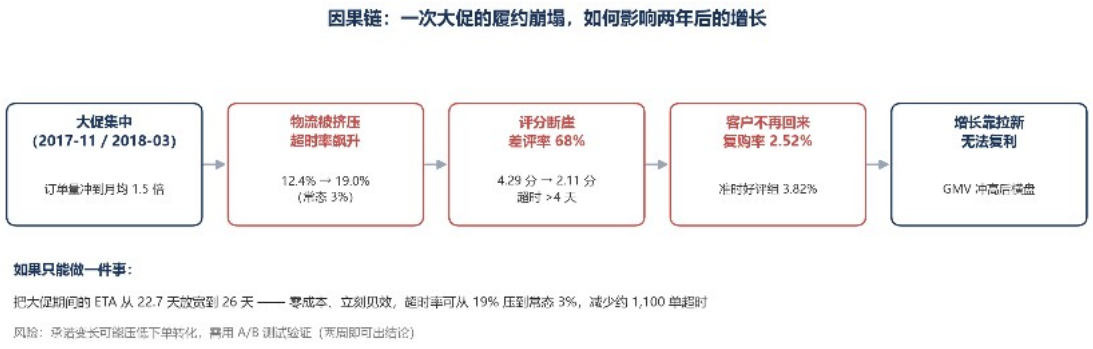


图 13　因果链：一次大促的履约崩塌，如何影响两年后的增长

三条建议（按单位成本效果排序）

#	建议	依据	效果	成本
1	大促期间 ETA 放宽 15%	缓冲 6.5 天时超时率 19%，缓冲 19 天时仅 1.16%	减 1,100 单超时 / 590 个差评	零
2	按州设 SLA	SP 8.7 天 vs PA 23.7 天，统一承诺两头都不公平	减 2,190 单超时 / 1,160 个差评	低
3	超时预警前置 1 天	超 4 天后评分已崩到 2.11，补救无效	减 320 个差评	中

> 超时率不是物流指标，是承诺管理指标。同样的履约能力，承诺定得松一点，差评就少一半。

必须诚实的一段：财务收益很小

把三条建议折算成 GMV：每减少 1 个差评 ≈ 挽回 0.013 个复购客户；每复购客户 ≈ 205 元；三条建议共减少约 2,000 个差评 ≈ 5,400 元，占半年 GMV 的 0.04%。

如果只用 GMV 衡量，这三条不值得做。但这不是结论，是数据边界的暴露——本数据集没有「转化率」和「卖家留存」，而评分的真实价值恰在这两处：4.3 分与 2.1 分的店铺转化率差多少？评分差导致多少卖家流失？都算不出来。

8 局限与展望

局限	影响	需要补什么
无转化率 / 曝光数据	无法量化评分的商业价值	埋点数据（曝光、点击、下单）
复购率仅 4–5%	复购类结论统计功效低	更长的时间窗
观察期右截断	近期 cohort 复购率被低估	已用 2018-04 前首购控制
无成本数据	算不出毛利，只能谈 GMV	财务口径
观察性数据	因果靠控制变量推断，非随机实验	建议 1 用 A/B 测试验证

三条建议均需验证：建议 1 用 A/B 测试，建议 2 用分州对照，建议 3 用小流量试点；成功标准分别是超时率降 50%、偏远州超时率降 30%、预警组差评率降 15 个百分点。

方法与复盘

- 口径决定结论：超时率按整天 6.77%、按小时 8.11%；复购率 3.12% 与 5.51%。报数先报口径。
- 相关之后要反驳自己：按州验证，每个州都掉 1.7–2.4 分。
- 显著不等于重要：复购差异 p<0.001 但只有 1.3 个百分点；财务收益折算仅 5,400 元。

复现与数据来源

环境 MySQL 8.0 + Python 3.14；执行 sql/01_load_all.sql 建库导入，依次运行 sql/02~05，再由 src/ 下的脚本取数与出图。数据来源：Kaggle，Brazilian E-Commerce Public Dataset by Olist（9 张表 / 155 万行 / 2016-09 至 2018-10）。

字段说明见 docs/data_dictionary.md，数字校验过程见 docs/reconciliation_log.md。